

Prøve eksamensopgave i statistik

Til kalibrering af en elektronisk vægt er der udført en række målinger af udgangsspændingen af transduceren ved forskellige vægtbelastninger. Målingerne er angivet i tabellen.

Vægt [kg]	10	20	30	40	50	60	70	80	90	100
Spænding [mV]	3,11	5,68	9,41	11,58	15,42	18,18	20,87	24,25	26,58	30,42

- A:** Antag den lineære regressionsmodel og angiv modellen på symbolform
- B:** Beregn modellens parametre (hældningen af den lineære model og skæringen med y-aksen). Angiv hvorledes disse er beregnet.
- C:** Plot datapunkterne og regressionslinen udfra de beregnede parametre
- D:** Beregn R^2 værdien og fortolk resultatet
- E:** Brug hypotesetesten

$$H_0: \beta_1 = 0 \text{ og } H_1: \beta_1 \neq 0$$

og vurder, om der er evidens for en lineær sammenhæng mellem **Vægt** og **Spænding** ved et signifikansniveau på 5 %.

Løsning

A:

- Vi antager en **simpel lineær regression** mellem vægt x (kg) og spænding y (mV):

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

hvor:

- y_i : observeret spænding
- x_i : vægtbelastning
- β_0 : skæringspunkt med y-aksen
- β_1 : hældningen (ændring i spænding pr. kg)
- ε_i : residual (fejllid)

B:

Model parametrene beregnes med formlerne

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

hvor:

$$\bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i$$

Python kode til udregning:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

n=10
x = np.array([10, 20, 30, 40, 50, 60, 70, 80, 90, 100])
y = np.array([3.11, 5.68, 9.41, 11.58, 15.42, 18.18, 20.87, 24.26, 26.58, 30.42])

x_mean = (1/n)*np.sum(x)
y_mean = (1/n)*np.sum(y)

beta_1_hat = np.sum((x - x_mean) * (y - y_mean)) / np.sum((x - x_mean)**2)
beta_0_hat = y_mean - beta_1_hat * x_mean
```

beta_0_hat	float64	1	np.float64(-0.01466666666667038)
beta_1_hat	float64	1	np.float64(0.3011939393939394)

Regressionen er altså:

$$\hat{y} = -0.0147 + 0.3012x$$


Det betyder, at spændingen stiger med ca. **0.301 mV pr. kg belastning**, og at spændingen ved 0 kg teoretisk set er meget tæt på 0 mV.

C:

Python kode til plot:

```
y_hat = beta_0_hat + beta_1_hat * x

plt.scatter(x, y, color='blue')
plt.plot(x, y_hat, color='red')
plt.xlabel("Vægt [kg]")
plt.ylabel("Spænding [mV]")
plt.title("Lineær regression: Spænding som funktion af Vægt")
plt.grid(True)
```



D:

R^2 værdien kan beregnes med formel

$$R^2 = \frac{s_{xy}^2}{s_{xx} s_{yy}}$$

Hvor

$$s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2, \quad s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Python kode til udregning:

```
s_xx = np.sum((x - x_mean)**2)
s_yy = np.sum((y - y_mean)**2)
s_xy = np.sum((x - x_mean) * (y - y_mean))

R2 = (s_xy**2) / (s_xx * s_yy)
```

R2	float64	1	np.float64(0.9985759236375679)
----	---------	---	--------------------------------

Fortolkning: **ca. 99.9 % af variationen i spænding** kan forklares af den lineære model med vægt som forklarende variabel. Datapunkterne ligger derfor **meget tæt** på regressionslinjen.

E:

Vi tester, om der overhovedet er en lineær sammenhæng:

$$H_0: \beta_1 = 0, H_1: \beta_1 \neq 0$$

Dette er en **tosidet test**, fordi vi undersøger, om β_1 er forskellig fra 0 i **begge retninger** — både større eller mindre.

Vi bruger teststatistikken

$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{s_r^2 / s_{xx}}}$$

Hvor

$$\beta_{1,0} = 0 \text{ under } H_0, \text{ og}$$

$$s_r^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2.$$

P-værdi beregnes med formel (tosidet test):

$$p\text{-value} = 2(1 - t_{\text{cdf}}(|t|, n - 2))$$

Python kode til udregning:

```
s_r2 = (1/(n-2)) * np.sum((y - y_hat)**2)

s_xx = np.sum((x - x_mean)**2)

beta1_0 = 0

t_value = (beta_1_hat - beta1_0) / np.sqrt(s_r2 / s_xx)

p_value = 2 * (1 - stats.t.cdf(np.abs(t_value), df=n-2))
```

p_value	float64	1	np.float64(1.1251000131551336e-12)
---------	---------	---	------------------------------------

Da $p \ll 0.05$ så **forkaster vi nulhypoten.**

Der er meget stærk statistisk evidens for, at hældningen β_1 er forskellig fra 0.

Altså: der er en signifikant lineær sammenhæng mellem **Vægt** og **Spænding**.