

Prøve eksamensopgave i statistik

For en bestemt type batterier angives i specifikationen fra leverandøren, at levetiden T for

batterierne er normalfordelt med en middellevetid på 3000 timer med en standard afvigelse på

100 timer: $T \sim N(3000, 100^2)$

Der udtages tilfældigt 12 batterier af pågældende type. Ved en test måles levetiden af disse til:

Batteri nr.	1	2	3	4	5	6	7	8	9	10	11	12
Levetid T (timer)	3148	2956	2803	2933	2869	3111	2789	2995	2909	2929	3148	2867

- A: Opstil en hypotese test for at bestemme om middellevetiden for batteritypen stemmer med leverandørens specifikation.
- B: Bestem den estimerede middellevetid for batteritypen.
- C: Opstil udtryk for og beregn p-værdien. Kan vi afvise nulhypotesen på 5% signifikansniveau?
- D: Brug Box–Muller-metoden til at generere standard normalfordelte tal.
- $$Z \sim N(0,1)$$
- Generér $N=10$ stikprøver, hver med $n=12$ uafhængige standardnormalfordelte observationer.
- E: Lav en transformation af $Z \sim N(0,1)$ sådan at du får 10 simulerede stikprøver med fordelingen $T \sim N(3000, 100^2)$. Plot histogrammet.
- F: Brug den simulerede fordeling $Z \sim N(0,1)$ fra (D), og beregn hvor mange af de simulerede værdier der ligger udenfor intervallet $[-1.96, 1.96]$.
- Sammenlign med den forventede andel ved 5% signifikansniveau.

Løsning

A:

Vi tester om middelværdien er 3000 timer:

$$H_0 : \mu = 3000,$$

$$H_1 : \mu \neq 3000$$

(altså en **to-sidet test**, fordi vi både vil opdage, hvis levetiden er større eller mindre end 3000 timer).

B:

Stikprøvemiddelværdien bruges som estimator for μ :

$$\bar{T} = \frac{1}{n} \sum_{i=1}^n T_i$$

hvor $n = 12$ er antal målte batterier.

Python kode til udregning:

```
import numpy as np
import math
import matplotlib.pyplot as plt
from scipy import stats

T = np.array([3148, 2956, 2803, 2933, 2869, 3111,
              2789, 2995, 2909, 2929, 3148, 2867])

n = len(T)

T_mean = (1/n)*np.sum(T)
```

T_mean	float64	1	np.float64(2954.75)
--------	---------	---	---------------------

Den estimerede middellevetid er altså ca. **2955 timer**.

C:

Da $\sigma = 100$ er kendt, og T antages normalfordelt, bruger vi en **z-test**.

Teststatistikken:

$$Z = \frac{\bar{T} - \mu_0}{\sigma/\sqrt{n}} \sim N(0,1) \text{ under } H_0$$

to-sidet p-værdi:

$$p = 2(1 - \Phi(|z|))$$

hvor Φ er CDF'en for standardnormalfordelingen.

Python kode til udregning:

```
import numpy as np
import math
import matplotlib.pyplot as plt
from scipy import stats

T = np.array([3148, 2956, 2803, 2933, 2869, 3111,
              2789, 2995, 2909, 2929, 3148, 2867])

n = len(T)

T_mean = (1/n)*np.sum(T)

mu0 = 3000
sigma = 100

Z_obs = (T_mean-mu0)/(sigma/math.sqrt(n))

p = 2*(1-stats.norm.cdf(abs(Z_obs)))
```

mu0	int	1	3000
n	int	1	12
p	float64	1	np.float64(0.11699646934229402)
sigma	int	1	100
T	Array of int64	[12]	[3148 2956 2803 ... 2929 3148 2867]
T_mean	float64	1	np.float64(2954.75)
Z_obs	float64	1	np.float64(-1.5675059808498337)

Vi aflæser p-værdien: $p \approx 0.117 > 0.05$. Så vi kan ikke afvise nulhypotesen ved 5% signifikans niveau.

D:

Box–Muller-metoden:

Lad U_1, U_2 være uafhængige uniforme på $(0, 1)$.

Sæt

$$R = \sqrt{-2 \ln U_1}, \quad \theta = 2\pi U_2,$$

og

$$Z_1 = R \cos \theta, \quad Z_2 = R \sin \theta.$$

Så er $Z_1, Z_2 \sim N(0, 1)$, uafhængige.

Vi har brug for i alt

$$m = N \cdot n = 10 \cdot 12 = 120$$

standardnormalfordelte tal. Vi laver 120 Box–Muller-par, men bruger kun Z_1 .

Python kode til udregning:

```
import numpy as np
import math
import matplotlib.pyplot as plt
from scipy import stats

rng = np.random.default_rng(seed=123)

N = 10
n = 12
m = N * n

U = rng.random((2, m))
U1 = U[0]
U2 = U[1]

R = np.sqrt(-2 * np.log(U1))
theta = 2 * np.pi * U2

Z1 = R * np.cos(theta)    # Z1 ~ N(0,1), længde 120
print("De første 5 Z1-værdier:", Z1[:5])
```

```
De første 5 Z1-værdier: [ 0.84759423 -2.32780945 -0.74622529
-0.69560887  1.07391894]
```

Vi har nu genereret **120 standardnormalfordelte observationer** Z_1 , som kan betragtes som 10 stikprøver à 12 observationer fra $N(0,1)$.

E:

Hvis $Z \sim N(0, 1)$, så gælder for enhver lineær transformation

$$T = \mu + \sigma Z \Rightarrow T \sim N(\mu, \sigma^2).$$

Her ønsker vi

$$T \sim N(3000, 100^2),$$


så vi sætter

$$T = 3000 + 100Z.$$

Python kode til plot:

```
# fortsætter direkte efter koden i D
T_sim = 3000 + 100 * Z1
print("De første 5 T_sim-værdier:", T_sim[:5])

plt.hist(T_sim, bins=20, density=True, alpha=0.7)
plt.title("Histogram af 120 simulerede batterilevetider T")
plt.xlabel("T (timer)")
plt.ylabel("tæthed")
```



F:

For en standardnormalfordeling gælder:

$$P(|Z| > 1.96) = 2(1 - \Phi(1.96)) \approx 0.05.$$

Det vil sige, at vi **teoretisk** forventer, at ca. 5 % af observationerne ligger udenfor $[-1.96, 1.96]$.

Python kode til udregning af simulerede værdier der ligger udenfor intervallet

```
# Z1 fra opgave D (længde 120)
grænse = 1.96

# 1) Simuleret andel udenfor intervallet [-1.96, 1.96]
udenfor = np.abs(Z1) > grænse

antal_udenfor = np.sum(udenfor)
andel_udenfor = antal_udenfor / len(Z1)

print("Antal samples udenfor [-1.96, 1.96] =", antal_udenfor)
print("Simuleret andel udenfor =", andel_udenfor)

# 2) Teoretisk andel ved 5% signifikansniveau

andel_teoretisk = 2 * (1 - stats.norm.cdf(1.96)) # P(|Z| > 1.96)

print("Teoretisk andel (≈ 5%) =", andel_teoretisk)
```

```
Antal samples udenfor [-1.96, 1.96] = 6
Simuleret andel udenfor = 0.05
Teoretisk andel (≈ 5%) = 0.04999579029644097
```

Den simulerede/estimerede sandsynlighed

$$\hat{P}(|Z| > 1.96) = \frac{6}{120} = 0.05$$

Dette stemmer meget godt overens med den teoretiske andel på ca. 5 %.