

Prøve eksamensopgave i statistik

Et fødevarepakkeri bruger en automatiseret sensor til at opdage *forkert forseglede pakker*. Hver pakke passerer en sensor, som registrerer pakken som enten "OK" eller "Fejl".

Virksomheden antager, at sandsynligheden for at en pakke er fejlbehæftet er p , og at fejl optræder uafhængigt fra pakke til pakke.

I et kvalitetstjek analyserer man $n = 3000$ pakkede produkter og finder i alt **54 fejl**.

Lad $X_i = 1$ hvis pakke i er fejlbehæftet, og $X_i = 0$ ellers, så:

$$X_i \sim \text{Bernoulli}(p)$$
$$Y = \sum_{i=1}^{3000} X_i \sim \text{Binomial}(3000, p)$$

A: Find en punktestimator for p , og beregn estimatet ud fra data.

B: Er punktestimatoren $\hat{p}$ for p unbiased? Begrund svaret.

C: Verificér resultatet fra opgave B ved en simulering. Antag at $p = 0.018$ og $n = 3000$.

Simulér $N = 10000$ uafhængige stikprøver af

$$Y \sim \text{Binomial}(3000, p)$$

og beregn $\hat{p} = Y/n$ for hver stikprøve og find gennemsnittet.

D: Brug de simulerede værdier $\hat{p}$ fra opgave C til at undersøge fordelingen af estimatoren.

- Beregn sample varians af de 10000 værdier af $\hat{p}$.
- Sammenlign med den teoretiske varians: $\text{Var}(\hat{p}) = \frac{p(1-p)}{n}$

E: Antag at $p=0.18$ og benyt CLT til at beregne sandsynligheden for at finde mere end 54 fejl.

Løsning

A:

Den naturlige estimator for p er stikprøveproportionen

$$\hat{p} = \frac{Y}{n}$$

Beregning

$$\hat{p} = \frac{54}{3000} = 0.018.$$

B:

Middelværdien for Bernoulli fordelt stokastisk variabel X_i er

$$E[X_i] = p$$

Dermed er middelværdien for Binomial fordelt stokastisk variabel Y

$$E[Y] = E\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n E[X_i] = np$$

Middelværdien for punktestimatoren $\hat{p}$ er dermed

$$E[\hat{p}] = E\left[\frac{Y}{n}\right] = \frac{1}{n}E[Y] = \frac{1}{n} \cdot np = p$$

Så $\hat{p}$ er **unbiased** som estimator for p

C:

Hvis $\hat{p}$ er unbiased, bør gennemsnittet af de simulerede $\hat{p}$ ligge tæt på den sande værdi $p = 0,018$

Python-kode

```
p_true = 0.018
n = 3000
Nsim = 10000

Y_sim = np.random.binomial(n, p_true, size=Nsim)

# Beregn p_hat for hver simulering
p_hat_sim = Y_sim / n

# Gennemsnit af p_hat
p_hat_mean = p_hat_sim.mean()

print("Sand p          =", p_true)
print("Simuleret gennemsnit =", p_hat_mean)
```

```
Sand p          = 0.018
Simuleret gennemsnit = 0.018010966666666666
```

Det simulerede gennemsnit af $\hat{p}$ bliver numerisk meget tæt på $p = 0,018$. Dette bekræfter resultatet fra opgave B

D:

For en binomialfordeling gælder:

$$\text{Var}(Y) = np(1 - p).$$

Dermed:

$$\text{Var}(\hat{p}) = \text{Var}\left(\frac{Y}{n}\right) = \frac{1}{n^2} \text{Var}(Y) = \frac{np(1 - p)}{n^2} = \frac{p(1 - p)}{n}$$

Med $p = 0.018$ og $n = 3000$:

$$\text{Var}(\hat{p}) = \frac{0.018 \cdot 0.982}{3000} = 5.892 \cdot 10^{-6} \approx 0.00000589$$

Sample variansen (stikprøvevariansen) er defineret ved:

$$s_{\hat{p}}^2 = \frac{1}{N - 1} \sum_{k=1}^N (\hat{p}_k - \bar{\hat{p}})^2$$

Python kode:

```
import numpy as np
import math
import matplotlib.pyplot as plt
from scipy import stats

p_true = 0.018
n = 3000
Nsim = 10000

Y_sim = np.random.binomial(n, p_true, size=Nsim)

# Beregn p_hat for hver simulering
p_hat_sim = Y_sim / n

# Gennemsnit af p_hat
p_hat_mean = p_hat_sim.mean()

print("Sand p          =", p_true)
print("Simuleret gennemsnit =", p_hat_mean)

Sample_var = np.sum((p_hat_sim - p_hat_mean)**2) / (Nsim - 1)
print("Empirisk sample-variants s^2      =", Sample_var)
```

```
sample-variants s^2      = 5.832952788612194e-06
```

Vores model og teori for estimatoren er konsistent med de numeriske resultater.

E:

Med $Y \sim \text{Binomial}(n = 3000, p = 0.18)$:

$$E[Y] = np = 3000 \cdot 0.18 = 540,$$

$$\text{Var}(Y) = np(1 - p) = 3000 \cdot 0.18 \cdot 0.82 = 442.8,$$

$$\sigma = \sqrt{\text{Var}(Y)} \approx 21.04.$$

Ved Central Limit Theorem (CLT) approksimeres Y af en normalfordeling:

$$Z = \frac{Y - \mu}{\sigma} = \frac{Y - 540}{\sqrt{442.8}} \approx N(0, 1).$$

Vi ønsker:

$$P(Y > 54).$$

Brug CLT:

$$P(Y > 54) \approx P\left(\frac{Y - 540}{\sqrt{442.8}} > \frac{54 - 540}{\sqrt{442.8}}\right)$$

Så:

$$P(Y > 54) \approx 1 - \Phi(z_0).$$

Python kode:

```
import numpy as np
import math
import matplotlib.pyplot as plt
from scipy import stats

n = 3000
p = 0.18

mu = n * p
sigma = math.sqrt(n * p * (1 - p))

z0 = (54 - mu) / sigma

P = 1 - stats.norm.cdf(z0)
```

mu	float	1	540.0
n	int	1	3000
p	float	1	0.18
P	float64	1	np.float64(1.0)
sigma	float	1	21.04281350010022
z0	float	1	-23.09577091474414

$P(Y > 54) \approx 1$ så **mere end 54 fejl** er derfor *næsten sikkert*: