

Prøve eksamensopgave i statistik

Et fødevarelaboratorium ønsker at undersøge, om en ny dyrkningsmetode til tomater giver et højere naturligt indhold af C-vitamin end den traditionelle metode.

Der udtages derfor to stikprøver:

- 12 tomater dyrket med *traditionel metode*
- 10 tomater dyrket med *ny metode*

Alle tomater analyseres i laboratoriet for C-vitaminindhold. Da tomaterne kommer fra forskellige planter og drivhuse, antages stikprøverne at være uafhængige. Det antages også, at variationen i C-vitaminindhold kan beskrives ved en normalfordeling, og at variansen kan antages ens i de to populationer.

Målingerne (mg per 100g) er:

Traditionel metode

42.1, 39.8, 41.0, 40.2, 39.5, 42.4, 41.3, 40.9, 39.7, 40.4, 41.1, 40.0

Ny metode

44.2, 45.1, 43.7, 44.9, 45.4, 44.1, 43.9, 44.7, 45.0, 44.3

A: Skal forsøgsopstillingen analyseres som en uparret eller parret test? Forklar.

B: Formulér nulhypotese og alternativ hypotese for at teste, om den nye metode giver højere gennemsnitligt C-vitaminindhold.

C: Opstil et udtryk for den poolede varians og beregn denne.

D: Opstil udtryk for og beregn p-værdien. Kan vi afvise nulhypotesen på 5% signifikansniveau?

E: Opstil og beregn et 95% konfidensinterval for forskellen i C-vitaminindhold ved traditionel metode og ny metode.

F: Fortolk resultatet i opgave E og vurder om denne understøtter konklusionen fra opgave D

Løsning

A:

Hver observation stammer fra forskellige planter og drivhuse, og der er ingen naturlig parring (som én “gam-mel” og én “ny” tomat under samme forhold).

Derfor skal forsøgsopstillingen analyseres som en **uparret** test.

B:

Population 1: ny metode, middelværdi μ_1

Population 2: traditionel metode, middelværdi μ_2

Sand forskel givet ved

$$\delta = \mu_1 - \mu_2$$

Hypoteserne:

$$H_0: \delta = 0$$

$$H_1: \delta > 0 \text{ (en-sidet test da forskellen skal være positiv)}$$

C:

Stikprøvemiddelværdier:

$$\bar{X}_1 = \frac{1}{n_1} \sum_{j=1}^{n_1} X_{1j}, \quad \bar{X}_2 = \frac{1}{n_2} \sum_{i=1}^{n_2} X_{2i}$$

Stikprøvevarianser (populationsvarians er ukendt):

$$s_1^2 = \frac{1}{n_1 - 1} \sum_{j=1}^{n_1} (X_{1j} - \bar{X}_1)^2$$

$$s_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (X_{2i} - \bar{X}_2)^2$$

Pooled variance

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Python kode til udregning

```
import numpy as np
import math

# Data
trad = np.array([42.1, 39.8, 41.0, 40.2, 39.5, 42.4,
                 41.3, 40.9, 39.7, 40.4, 41.1, 40.0])
ny   = np.array([44.2, 45.1, 43.7, 44.9, 45.4,
                 44.1, 43.9, 44.7, 45.0, 44.3])

n1 = len(ny)
n2 = len(trad)

X1_bar = np.mean(ny)
X2_bar = np.mean(trad)

s1_2 = (1/(n1-1))*np.sum((ny-X1_bar)**2)
s2_2 = (1/(n2-1))*np.sum((trad-X2_bar)**2)

s_p2 = ((n1 - 1)*s1_2 + (n2 - 1)*s2_2) / (n1 + n2 - 2)
```

s_p2	float64	1	np.float64(0.62404999999999994)
------	---------	---	---------------------------------

Vi aflæser pooled varians til $s_p^2 \approx 0.62$

D:

Med pooled variance er teststørrelsen

$$t = \frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2}.$$

Under nulhypotesen $H_0: \mu_1 - \mu_2 = 0$ bliver det

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

En-sidet p-værdi:

$$p = 1 - t_{cdf}(t, df)$$

Python kode til udregning

```
# kode fra C genbruges
from scipy import stats
s_p = math.sqrt(s_p2)
SE = s_p * math.sqrt(1/n1 + 1/n2)
t    = (X1_bar - X2_bar) / SE
df   = n1 + n2 - 2
p = 1 - stats.t.cdf(t, df)
```

p	float64	1	np.float64(1.882827227461803e-10)
---	---------	---	-----------------------------------

Da p-værdien $p \approx 1.9 \cdot 10^{-10} \ll 0.05$, afviser vi nulhypotesen

E:

Konfidensintervallet med pooled variance:

$$\hat{\delta}_{\pm} = (\bar{X}_1 - \bar{X}_2) \pm t_{inv}(0.975, df) \cdot s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

hvor $t_{inv}(0.975, df)$ er den kritiske t-værdi

Python kode til udregning

```
# kode fra D genbruges

t_crit = stats.t.ppf(0.975, df) # t_inv(0.975, df)
delta_hat = X1_bar - X2_bar
ci_low = delta_hat - t_crit * SE
ci_high = delta_hat + t_crit * SE
```

ci_high	float64	1	np.float64(4.535565123273277)
ci_low	float64	1	np.float64(3.1244348767267196)

Konfidensintervallet er (3.12 ; 4.54)

F:

I D fandt vi en meget lille p-værdi, så vi **afviste** H_0 og konkluderede, at den nye metode giver højere gennemsnitligt C-vitaminindhold.

I E viste 95%-konfidensintervallet sig kun at indholde positive værdier. Det betyder, at en forskel på 0 *ikke* er forenelig med data på 5 %-niveau.

Dermed kommer både t-testen i D og konfidensintervallet i E frem til **samme konklusion**: