

Prøve eksamensopgave i statistik

Et team af softwareingeniører undersøger, hvordan systemets responstid påvirkes af belastning. For at analysere sammenhængen måles den gennemsnitlige responstid (i ms) ved forskellige antal samtidige API-forespørgsler. Resultaterne fremgår af tabellen:

Forespørgsler	10	20	30	40	50
Responstid (ms)	47	55	63	72	81

A: Antag en lineær regressionsmodel, og angiv modellen på symbolform.

B: Beregn modellens parametre (hældning og skæring med y-aksen), og angiv hvordan disse er beregnet.

C: Plot datapunkterne samt regressionslinjen ud fra de beregnede parametre.

D: Beregn modellens R^2 -værdi, og fortolk resultatet.

E: Lav et residualplot, og vurder om antagelserne for lineær regression virker rimelige for disse data.

F: Udfør en hypotesetest for signifikansen af hældningskoefficienten:

$$H_0: \beta_1 = 0 \text{ og } H_1: \beta_1 \neq 0$$

Vurder, om der er statistisk evidens for en lineær sammenhæng mellem belastning og responstid ved et signifikansniveau på 5%.

Løsning

A:

- Vi antager en **simpel lineær regression**:

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

hvor:

- y_i : responstid (ms)
- x_i : antal samtidige forespørgsler
- β_0 : skæringspunkt med y-aksen
- β_1 : hældningen (ændring i spænding pr. kg)
- ε_i : residual (fejllid)

B:

Model parametrene beregnes med formlerne

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

hvor:

$$\bar{x} = \frac{1}{n} \sum x_i, \quad \bar{y} = \frac{1}{n} \sum y_i$$

Python-kode til beregning

```
import numpy as np
import math

x = np.array([10, 20, 30, 40, 50], dtype=float)
y = np.array([47, 55, 63, 72, 81], dtype=float)

n = len(x)

x_bar = np.mean(x)
y_bar = np.mean(y)

S_xx = np.sum((x - x_bar)**2)
S_xy = np.sum((x - x_bar)*(y - y_bar))

beta1_hat = S_xy / S_xx
beta0_hat = y_bar - beta1_hat * x_bar
```

beta0_hat	float64	1	np.float64(38.1)
beta1_hat	float64	1	np.float64(0.85)

Regressionen er altså:

$$\hat{y} = 38,1 + 0,85x$$


C:

Python kode til plot:

```
import matplotlib.pyplot as plt

y_hat = beta0_hat + beta1_hat * x

plt.scatter(x, y)          # datapunkter
plt.plot(x, y_hat, color='red') # regressionslinje
plt.xlabel("Antal samtidige forespørgsler")
plt.ylabel("Responstid (ms)")
plt.title("Lineær regression: belastning vs. responstid")
```



D:

R² værdien kan beregnes med formel

$$R^2 = \frac{s_{xy}^2}{s_{xx} s_{yy}}$$

Hvor

$$s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2, \quad s_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Python kode til udregning:

```
s_xx = np.sum((x-x_bar)**2)
s_yy = np.sum((y-y_bar)**2)
s_xy = np.sum((x-x_bar)*(y-y_bar))

R2=(s_xy**2) / (s_xx*s_yy)
```

R2	float64	1	np.float64(0.9990320796460177)
----	---------	---	--------------------------------


Ca. 99.9 % af variationen i responstid forklares af den lineære sammenhæng med antal samtidige forespørgsler. Modellen passer **meget** godt til data.

E:

Python kode til plot:

```
y_hat = beta0_hat + betal_hat * x
residuals = y - y_hat

plt.scatter(x, residuals)
plt.axhline(0)
plt.xlabel("Antal samtidige forespørgsler")
plt.ylabel("Residual (ms)")
plt.title("Residualplot")
```



Residualerne er små (under 1 ms).

De er positive ved de mindste og største belastninger og lidt negative i midten → ganske let krumning (systemet vokser måske en anelse stærkere end lineært).

I praksis er afvigelserne dog så små, at den lineære model virker fuldt rimelig til kalibrering og grov kapacitetsplanlægning.

F:

Vi tester, om der overhovedet er en lineær sammenhæng:

$$H_0: \beta_1 = 0, H_1: \beta_1 \neq 0$$

Dette er en **tosidet test**, fordi vi undersøger, om β_1 er forskellig fra 0 i **begge retninger** — både større eller mindre.

Vi bruger teststatistikken

$$t = \frac{\hat{\beta}_1 - \beta_{1,0}}{\sqrt{s_r^2 / s_{xx}}}$$

Hvor

$\beta_{1,0} = 0$ under H_0 , og

$$s_r^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad s_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2.$$

P-værdi beregnes med formel (tosidet test):

$$\text{p-value} = 2(1 - t_{\text{cdf}}(|t|, n-2))$$

Python kode til udregning:

```
from scipy import stats

s_r2 = (1/(n-2)) * np.sum((y - y_hat)**2)

betal_0 = 0

t_value = (betal_hat - betal_0) / math.sqrt(s_r2 / s_xx)

p_value = 2 * (1 - stats.t.cdf(abs(t_value), df=n-2))
```

p_value	float64	1	np.float64(1.278422641415311e-05)
---------	---------	---	-----------------------------------

Da $p \ll 0.05$ så **forkaster vi nulhypoten**.

Der er meget stærk statistisk evidens for, at hældningen er forskellig fra 0, dvs. at der er en klar lineær sammenhæng mellem belastning (antal samtidige forespørgsler) og responstid.